

# Etapa 2 — Detecção de Faces Sintéticas

Relatório de Progresso: da Análise Espectral à Busca de Hiperparâmetros

Classificação binária real vs. sintético (rostos) e generalização cross-generator | ResNet-50 e EfficientNet-B2 | Data: 07/06/2026

## 1. Sumário Executivo

Esta etapa treina redes profundas para distinguir rostos reais de rostos gerados por IA. A descoberta central é que o problema fácil e o problema difícil são diferentes: classificar imagens do **mesmo** gerador de treino (StyleGAN) é trivial — a ResNet-50 atinge **AUC 0,997** no teste in-distribution — mas generalizar para imagens de **outros** geradores (o conjunto ArtiFact) despenca para **AUC 0,63**. Esse abismo é o foco de toda a investigação.

**O que funcionou:** augmentation aleatória de degradação (**jpeg+noise**) elevou a AUC cross-generator de **0,632** (raw) para **0,687** — um ganho real e bem medido (5 seeds, desvio 0,006).

**O que não funcionou:** a busca de hiperparâmetros do otimizador (learning rate, dropout, weight decay) **não trouxe ganho**: nenhuma das 20 configurações superou o default, e o efeito dos HP (~0,010) foi menor que o ruído entre seeds (~0,023).

**Por quê (mecanismo):** a análise espectral mostrou que o StyleGAN deixa uma *assinatura de frequência* que a CNN aprende trivialmente. O ganho de generalização vem de **destruir essa assinatura na imagem** (augmentation), não de afinar o otimizador. Esse achado define a direção dos próximos passos.

## 2. Bases de Dados

O projeto usa **duas** bases com papéis distintos — é essa separação que permite medir generalização honesta (treinar num gerador, testar em outros).

### 2.1 140k Real and Fake Faces — treino / validação / teste (in-distribution)

Base do Kaggle com **70.000 imagens reais** (rostos do CelebA) e **70.000 sintéticas** (geradas por **StyleGAN**), já balanceada. Substituíu a CelebA Align da Etapa 1. É a única fonte de treino — portanto o modelo só vê *um* gerador durante o aprendizado.

### 2.2 ArtiFact (faces) — validação / teste cross-generator

Base do Kaggle com imagens de **múltiplos geradores** (StyleGAN, ProGAN, Stable Diffusion, DALL-E, entre outros). Filtramos apenas **rostos humanos**. Os rótulos vêm da fonte: reais = *ffhq, celebahq, metfaces*; falsas = qualquer outro gerador de faces. Cada imagem guarda a fonte num *manifest*, o que permite até excluir a própria família StyleGAN para um teste puramente cross-generator. É o nosso termômetro de generalização: **fixo e balanceado** em todos os experimentos, avaliado por **AUC** (robusta a desvio de calibração entre geradores).

## 3. Pipeline de Investigação (01b a 01f)

A série **01** é exploratória: roda em regime barato (ResNet-50, 10 épocas, 5% do 140k) para isolar, com rapidez e múltiplas seeds, o que de fato move a métrica cross-generator antes de treinar os modelos finais.

### 3.1 01b — Análise Espectral: a digital do StyleGAN

Via FFT, comparou o espectro médio de imagens reais, falsas (StyleGAN) e falsas comprimidas. Conclusão: o StyleGAN deixa **resíduos de alta frequência** que as CNNs aprendem *trivialmente* — exatamente o atalho que explica o AUC 0,99 instantâneo na fonte. A varredura de qualidade JPEG (q=100 a 50) revelou uma **curva em U**: existe um ponto ótimo de compressão onde o espectro do fake mais se aproxima do real (mínimo da distância espectral).

### 3.2 01c — Grad-CAM: o que o modelo olha

Mapas de ativação mostram que o modelo nem sempre foca em semântica facial (olhos, pele); o espectro 2D confirma o **grid 8x8 da compressão JPEG** como pontos brilhantes. Corroborar a tese: parte da decisão se apoia em artefatos, não em conteúdo — daí a má generalização.

### 3.3 01d — Sweep de pré-processamento fixo (cross-generator)

Varredura de 5 degradações aplicadas de forma **fixa** ao dataset. Todas superaram o raw (0,632), confirmando que atenuar a digital ajuda. Melhor método isolado: **JPEG q=70**.

| Método    | Melhor valor | AUC ArtiFact | Desvio |
|-----------|--------------|--------------|--------|
| jpeg      | q = 70       | 0,678        | 0,021  |
| downscale | fator 1,25   | 0,669        | 0,006  |
| median    | tam. 3       | 0,663        | 0,012  |
| noise     | sigma 0,03   | 0,662        | 0,017  |
| blur      | raio 1,0     | 0,656        | 0,002  |

Baseline sem pré-processamento (raw): **0,632**.

### 3.4 01e — Grid de augmentation aleatória (fase vencedora)

Em vez de degradação fixa, aqui a degradação é **aleatória por imagem e por época** (com prob. p=0,6, sorteia método e intensidade de um pool). É mais forte porque não deixa resíduo consistente para o modelo memorizar. Testou as 15 combinações de {jpeg, blur, downscale, noise}; as 3 melhores foram desempatadas com **5 seeds**.

| Pool (aleatório)        | AUC ArtiFact | Desvio | min   | max   |
|-------------------------|--------------|--------|-------|-------|
| jpeg + noise (vencedor) | 0,687        | 0,006  | 0,681 | 0,697 |
| jpeg + blur + noise     | 0,684        | 0,015  | 0,661 | 0,703 |
| blur + downscale        | 0,675        | 0,010  | 0,669 | 0,693 |

Baselines: raw **0,632** | jpeg fixo q70 **0,678**. O **jpeg+noise** venceu por combinar a maior média com a **menor variância** — sinal robusto, não sorte.

### 3.5 01f — Busca de hiperparâmetros (resultado negativo)

Fixada a augmentation vencedora, fizemos random search de lr, dropout e weight decay (20 configs x 2 seeds = 40 runs). O resultado é um **platô**: nenhuma config superou o default, e a análise de variância mostra por quê.

| Métrica de diagnóstico               | Valor       | Leitura                              |
|--------------------------------------|-------------|--------------------------------------|
| Efeito dos HP (desvio entre configs) | 0,010       | minúsculo                            |
| Ruído de seed (desvio intra-config)  | 0,023       | maior que o efeito                   |
| Configs acima do default (0,687)     | 0 / 20      | nenhuma                              |
| corr(learning rate, AUC cross-gen)   | -0,30       | único sinal: lr alto piora           |
| corr(dropout, AUC cross-gen)         | -0,01       | inerte                               |
| val_auc_140k de todas as configs     | 0,99 a 1,00 | fonte saturada: métrica interna cega |

Mecanismo: como a fonte (StyleGAN) é resolvida por qualquer config (val ~0,99), o único hiperparâmetro com efeito é o learning rate — e só porque lr alto afasta mais a rede das features pré-treinadas do ImageNet, destruindo o conhecimento geral que ajuda a generalizar. Dropout e weight decay (acoplado ao Adam) não tocam nesse eixo.

## 4. Modelos Treinados (03 / 04)

Os notebooks finais treinam os modelos completos. O número que importa é o contraste entre as duas colunas: desempenho excelente na fonte, fraco fora dela.

| Modelo          | AUC in-distribution (teste 140k) | AUC cross-generator (ArtiFact) |
|-----------------|----------------------------------|--------------------------------|
| ResNet-50 (raw) | 0,9975                           | 0,6316                         |
| EfficientNet-B2 | pendente (não treinado)          | pendente                       |

Observação importante: o modelo ResNet-50 salvo em disco ainda é a versão **raw** (sem a augmentation vencedora). A integração do jpeg+noise foi feita no código dos notebooks 03/04, mas **ainda não foi re-treinada**; a EfficientNet-B2 ainda não foi treinada. Logo, os modelos finais ainda não incorporam o principal ganho descoberto.

## 5. Descobertas: Sucessos e Falhas

### Sucessos

- **Diagnóstico do problema real:** separar in-distribution (trivial, 0,997) de cross-generator (difícil, 0,63) — o gap é a métrica que importa.
- **Explicação mecanicista:** análise espectral (01b) + Grad-CAM (01c) mostram que o modelo se apoia na digital de frequência do StyleGAN.
- **Protocolo de avaliação rigoroso:** ArtiFact fixo e balanceado, métrica AUC, múltiplas seeds para separar sinal de ruído, salvamento incremental.
- **Augmentation que funciona:** jpeg+noise elevou o cross-generator de 0,632 para 0,687 (+0,055), bem medido (5 seeds, desvio 0,006).
- **Engenharia sólida:** aug\_utils.py importável (permite num\_workers>0 no Windows) e split disjunto dev/test do ArtiFact (avaliação sem vazamento).

### Falhas e limitações

- **Ajuste de hiperparâmetros não ajudou:** 0/20 acima do default; efeito (0,010) menor que o ruído de seed (0,023). Único achado: evitar learning rate alto (> 3e-4).
- **Teto cross-generator ainda baixo:** ~0,69 contra 0,997 in-distribution. Os modelos ainda generalizam mal para geradores não vistos.

- **Métrica interna cega para seleção:** a fonte satura (val ~0,99 para tudo), então não dá para selecionar HP por ela.
- **Ganho ainda não consolidado nos modelos finais:** ResNet-50 salvo é raw; EfficientNet-B2 não treinada. A augmentation vencedora precisa ser re-treinada.

## 6. Próximos Passos

---

A direção é clara: o ganho vem de **atacar a imagem** (impedir o aprendizado da digital do StyleGAN), não de afinar o otimizador.

- **Atacar a imagem mais forte:** levar os destruidores de digital (blur, downscale — fortes no sweep/grid) para dentro do pool aleatório, possivelmente encadeados, com intensidade guiada pela curva em U da 01b.
- **Preservar features pré-treinadas:** congelar camadas iniciais / learning rate discriminativo, para a rede não esquecer o conhecimento geral do ImageNet (atacando o mecanismo que o lr baixo revelou).
- **Early-stopping no sinal cross-generator:** escolher a época pelo ArtiFact-dev (agora disjunto do teste), já que a métrica in-distribution é cega.
- **Consolidar:** re-treinar ResNet-50 e treinar EfficientNet-B2 com a receita vencedora e reportar o número final na metade de teste do ArtiFact.

---

Relatório gerado a partir dos resultados salvos em *artifacts/* (sweep, aug\_grid, hp\_search) e das métricas dos modelos em *artifacts/models/*.